

گزارش مدل‌های Atelier

میلاد حسنی

این گزارش پروژه Atelier است. نوشتنش تا روشن باشد چرا این هفت وزن را گذاشتم، هر کدام روی چه لباسی بهتر است، و از لپ‌تاپ RTX 4070 هشت‌گیگی‌ام چه انتظاری دارم. نسخه یک فقط استنتاج است؛ آموزش مجدد را عمداً نگذاشتم. اگر کارت محلی کم بیاید، روی Hugging Face هم می‌شود اجرا کرد.

۵/۴۲۵ بهترین FID زوجی مقاله روی VITON-HD	۲۴ گیگ + کلاس بومی FLUX	۸ گیگ کلاس VRAM خانواده SD 1.5	۷ وزن قابل انتخاب در منو
---	-----------------------------------	--	------------------------------------

چطور Atelier را چیدم

وقتی می‌گویم چک‌پوینت

منظورم یک فایل وزن ذخیره‌شده است؛ همان اعدادی که شبکه بعد از آموزش یاد گرفته. مقاله ICLR معمولاً می‌گوید pretrained model یا weights. مخزن CatVTON و Hugging Face همان فایل را checkpoint می‌نامند. در منو هفت گزینه دارم، ولی هفت معماری جدا نیست. چهار تای SD فقط آداپتور توجه را عوض می‌کنند. سه تای FLUX وزن Fill یا LoRA را بار می‌کنند.

مسیر همیشه یکی است. عکس شخص، عکس لباس، و نوع لباس — بالاتنه، پایین‌تنه یا تمام‌قد. برای ماسک به‌جای DensePose و SCHP مقاله، SegFormer لباس را گذاشتم تا روی ویندوز بدون Detectron2 نصب شود. بعد یکی از دو موتور دیفیوژن صدا زده می‌شود.

خانواده FLUX — ورود HF ستون فقرات gated مدل FLUX.1-Fill-dev. دو LoRA سبک و یک fine-tune کامل. Guidance اینجا ۳۰ است. روی کارت کوچک، Offload Sequential یا ۴-بیت را گذاشتم؛ کار می‌کند، ولی کندتر از حالت GPU است. FLUX رسمی · Alpha · Beta	خانواده ۴ — SD 1.5 آداپتور یک UNet اینپینت مشترک، حدود هشت گیگ. وقتی مدل را عوض می‌کنم فقط حدود ۱۹۸ مگابایت وزن توجه جابه‌جا می‌شود. Guidance را ۲/۵ گذاشتم. این آداپتورها را بدون ورود Hugging Face می‌شود گرفت. Mix · VITON-HD · DressCode · Mask-Free
---	---

کیفیت را با پیش‌تنظیم عوض می‌کنم: Tiny برابر ۲۸۴×۲۵۶ و ۱۶ گام، Fast برابر ۵۱۲×۳۸۴ و ۲۰ گام، Balanced برابر ۷۶۸×۵۷۶ و ۲۰ گام، Quality برابر ۱۰۲۴×۷۶۸ و ۵۰ گام، Studio برابر ۱۰۲۴×۱۲۸۰ و ۲۶ گام. اگر VRAM را روی Auto بگذارم و کارت از ۲۴ گیگ کوچک‌تر باشد، FLUX خودش به Offload یا ۴-بیت می‌رود.

این چهار عدد را چطور می‌خوانم

مقاله CatVTON چهار معیار می‌دهد. دو تای اول یک جفت تصویر را با هم می‌سنجند — خروجی در برابر عکس واقعی همان شخص با همان لباس. دو تای بعدی کل مجموعه خروجی را با کل مجموعه واقعی مقایسه می‌کنند و برای تست غیرزوجی هم به کار می‌آیند.

معیار	چه چیزی را می‌سنجد	بهرتر بودن	واحد تقریبی	ضعف
SSIM	شباهت ساختاری پیکسلی: روشنایی، کنتراست، لبه	بیشتر (نزدیک ۱)	۰ تا ۱	تصویر تار ولی تراز را گاهی بهتر از تصویر تیز جابه‌جاشده می‌داند
LPIPS	شباهت ادراکی در فضای ویژگی شبکه عمیق	کمتر	معمولاً ۰٫۰۴ تا ۰٫۲۰	به شبکه ویژگی وابسته است؛ چهره را جدا پاداش نمی‌دهد
FID	فاصله دو توزیع تصویر در فضای Inception	کمتر	بدون واحد؛ حدود ۳ تا ۱۵ در این جداول	به تعداد نمونه و کد ارزیابی حساس است
KID	همان ایده با هسته؛ بدون فرض گاوسی	کمتر	بدون واحد؛ روی مجموعه کوچک پایدارتر از FID	هنوز به فضای Inception وابسته است

SSIM — Structural Similarity Index

تصویر ساخته‌شده را پنجره‌به‌پنجره با عکس واقعی می‌سنجد: روشنایی محلی، کنتراست و لبه چقدر یکی است. خروجی بین صفر و یک است. در try-on زوجی، SSIM بالا برای من یعنی صورت، مو، پس‌زمینه و شبیه بدن سر جایش مانده — نه اینکه لباس لزوماً قشنگ‌تر شده. در جدول مقاله، CatVTON اینپینت روی VITON-HD به ۰٫۸۷۰۴ می‌رسد. ساختار کلی خیلی نزدیک است؛ دو تصویر یکی نیستند.

LPIPS — Learned Perceptual Image Patch Similarity

اینجا دیگر پیکسل خام ملاک نیست. تکه‌های تصویر از یک شبکه آموزش‌دیده — معمولاً VGG یا AlexNet — رد می‌شوند و فاصله ویژگی حساب می‌شود. چشم به بافت و چین حساس‌تر از اختلاف RGB است؛ LPIPS همان را تقریب می‌زند. کمتر بهتر است. اگر لباس درست بنشیند ولی رنگ یا بافت کمی فرق کند، LPIPS بیشتر از SSIM جریمه می‌کند. عدد اینپینت روی VITON-HD برابر ۰٫۰۵۶۵ است.

FID — Fréchet Inception Distance

این یکی برای یک جفت عکس نیست. همه تصاویر واقعی و همه خروجی‌ها با Inception به بردار تبدیل می‌شوند، برای هر مجموعه میانگین و کوواریانس گرفته می‌شود، و فاصله فرشه بین دو گاوسی حساب می‌شود. FID پایین یعنی توزیع خروجی به عکس‌های واقعی شبیه است. ضعفش این است که کد ارزیابی و تعداد نمونه عدد را جابه‌جا می‌کند. برای همین FIDهایی که جامعه برای FLUX گذاشته را با جدول مقاله قاطی نمی‌کنم.

KID — Kernel Inception Distance

همان فضای Inception، ولی به جای فرض گاوسی از یک هسته (MMD) استفاده می‌کند. روی چند هزار تصویر از FID پایدارتر است. مقاله هر دو را می‌دهد چون FID در ادبیات جا افتاده و KID برای این دیتاست‌ها قابل‌اعتمادتر است. روی VITON-HD زوجی، CatVTON به ۰٫۴۱۱ می‌رسد و OOTDiffusion به ۰٫۴۰۸۶.

قبل از مدل چه کار می‌کنم

هر هفت وزن از یک ورودی یکسان شروع می‌شوند. اختلاف فقط از مرحله دیفیوژن به بعد است.

گام	چه می‌کند	کجا در کد
۱. بوم	شخص را برش می‌دهم؛ لباس را با پد به همان اندازه می‌رسانم	resize_and_crop / padding
۲. پارس بدن	SegFormer لباس ۱۸ بخش می‌چسباند؛ صورت، لباس بالا، شلوار، دست	CPU روی ClothMasker
۳. ماسک آگنوستیک	بسته به upper / lower / overall ناحیه لباس گشاد می‌شود؛ صورت و مو را نگه می‌دارم	build_agnostic_mask
۴. نرم‌کردن لبه	ماسک را محو می‌کنم تا مرز لباس پاره نشود	blur_mask
۵. دیفیوژن	SD 1.5 یا FLUX ناحیه ماسک‌شده را با شرط لباس از نو می‌سازد	CatVTONPipeline یا FluxFill

مقاله برای همین ماسک DensePose و SCHP دارد. من SegFormer را جایگزین کردم تا نصب ویندوز ساده بماند. Mask-Free را برای وقتی گذاشتم که لبه ماسک روی بند و چاپ شلوغ ضعیف می‌شود.

اعداد مقاله CatVTON

چطور این جدول‌ها را می‌خوانم

FID و KID هرچه کمتر بهتر. SSIM هرچه بیشتر بهتر. LPIPS هرچه کمتر بهتر. زوجی یعنی عکس مرجع وجود دارد. غیرزوجی فقط توزیع را می‌سنجد. اعداد FLUX جامعه را جدا نگه داشتم چون با همین پروتکل گرفته نشده‌اند.

FID زوجی روی VITON-HD — کمتر بهتر است

۵٫۴۲۵		CatVTON
۵٫۷۶۲		IDM-VTON
۵٫۸۸۸		Mask-Free
۹٫۳۰۵		OOTDiffusion

منبع: Chong و همکاران، ICLR 2025، جدول ۱، تنظیم زوجی VITON-HD. محور مقدار FID است؛ واحد ندارد.

زمان استنتاج مقاله در ۷۶۸×۱۰۲۴ — ثانیه

۹٫۲۵ ثانیه		CatVTON
۱۷٫۳۲ ثانیه		IDM-VTON
۳۶٫۱۰ ثانیه		StableVTON
۳۶٫۲۳ ثانیه		OOTDiffusion

منبع: جدول ۲ همان مقاله. سخت‌افزار دیتاسنتر است، نه لپ‌تاپ من.

حافظه استنتاج – گیگابایت

۴٫۰ گیگ		CatVTON مقاله
۵٫۹ گیگ		Atelier Balanced
۱۰٫۲ گیگ		OOTDiffusion
۲۴ گیگ		FLUX بومی
۲۶٫۰۴ گیگ		IDM-VTON

جدول ۳ مقاله به علاوه اندازه گیری Balanced روی لپ تاپم.

جدول کامل مقاله روی VITON-HD

روش	↑ SSIM	↓ FID زوجی	↓ KID زوجی	↓ LPIPS	↓ FID غیرزوجی	↓ KID غیرزوجی
CatVTON اینپیننت	۰٫۸۷۰۴	۵٫۴۲۵	۰٫۴۱۱	۰٫۰۵۶۵	۹٫۰۱۵	۱٫۰۹۱
CatVTON Mask-Free	۰٫۸۷۰۱	۵٫۸۸۸	۰٫۵۱۳	۰٫۰۶۱۳	۹٫۲۸۷	۱٫۱۶۸
IDM-VTON	۰٫۸۴۹۹	۵٫۷۶۲	۰٫۷۳۲	۰٫۰۶۰۳	۹٫۸۴۲	۱٫۱۲۳
OOTDiffusion	۰٫۸۱۸۷	۹٫۳۰۵	۴٫۰۸۶	۰٫۰۸۷۶	۱۲٫۴۰۸	۴٫۶۸۹
GP-VTON	۰٫۸۷۰۱	۸٫۷۲۶	۳٫۹۴۴	۰٫۰۵۸۵	۱۱٫۸۴۴	۴٫۳۱۰
StableVTON	۰٫۸۵۴۳	۶٫۴۳۹	۰٫۹۴۲	۰٫۰۹۰۵	۱۱٫۰۵۴	۳٫۹۱۴
LaDI-VTON	۰٫۸۶۰۲	۱۱٫۳۸۶	۷٫۲۴۸	۰٫۰۷۳۳	۱۴٫۶۴۸	۸٫۷۵۴

جدول کامل مقاله روی DressCode

روش	↑ SSIM	↓ FID زوجی	↓ KID زوجی	↓ LPIPS	↓ FID غیرزوجی	↓ KID غیرزوجی
CatVTON اینپیننت	۰٫۸۹۲۲	۳٫۹۹۲	۰٫۸۱۸	۰٫۰۴۵۵	۶٫۱۳۷	۱٫۴۰۳
CatVTON Mask-Free	۰٫۹۰۱۶	۴٫۷۷۹	۱٫۲۹۷	۰٫۰۴۵۲	۷٫۴۰۰	۲٫۶۱۹
OOTDiffusion	۰٫۸۸۵۴	۴٫۶۱۰	۰٫۹۵۵	۰٫۰۵۳۳	۱۲٫۵۶۷	۶٫۶۲۷
IDM-VTON	۰٫۸۷۹۷	۶٫۸۲۱	۲٫۹۲۴	۰٫۰۵۶۳	۹٫۵۴۶	۴٫۳۲۰
GP-VTON	۰٫۷۷۱۱	۹٫۹۲۷	۴٫۶۱۰	۰٫۱۸۰۱	۱۲٫۷۹۱	۶٫۶۳۷
LaDI-VTON	۰٫۷۶۵۶	۹٫۵۵۵	۴٫۶۸۳	۰٫۲۳۶۶	۱۰٫۶۷۶	۵٫۷۸۷

وزن DressCode مقاله فقط روی DressCode آموزش دیده. Mix را که من پیش فرض گذاشتم روی حدود ۴۸ هزار جفت ترکیبی در ۱۰۲۴ پیکسل آموزش دیده و جدول رسمی جداگانه ای در مقاله ندارد.

سبکی معماری در مقاله

روش	پارامتر کل (میلیون)	قابل آموزش (میلیون)	حافظه (کیگ)	زمان ۲۸۴×۵۱۲	زمان ۷۶۸×۱۰۲۴
CatVTON	۸۹۹	۴۹/۵۷	۴/۰۰	۲/۵۸ ثانیه	۹/۲۵ ثانیه
StableVTON	۱۶۰۸	۵۰۱	۷/۸۷	۱۲/۱۷ ثانیه	۲۶/۱۰ ثانیه
OOTDiffusion	۲۱۹۱	۱۷۱۹	۱۰/۳۰	۴/۷۶ ثانیه	۲۶/۳۳ ثانیه
IDM-VTON	۶۲۳۸	۲۸۷۱	۲۶/۰۴	۱۲/۹۶ ثانیه	۱۷/۳۳ ثانیه

جداول ۲ و ۳. CatVTON انکودر متن و ReferenceNet را برداشته و فقط self-attention را آموزش داده است.

اعداد جامعه FLUX — پروتکل جدا

این‌ها را با جدول بالا جمع نمی‌زنم

نویسندۀ جامعه این FIDها را با مقیاس ۳۰ و ۳۰ گام روی VITON-HD گزارش کرده. پیش‌پردازش ماسک، رزولوشن و کد ارزیابی با مقاله یکی اعلام نشده.

وزن	نوع	داده آموزش	FID اعلام شده	پیکربندی تست
FLUX Alpha کامل	fine-tune ترنسفورمر	فقط VITON-HD	۵/۵۹۳	مقیاس ۳۰۰۳۰ گام
FLUX LoRA Alpha	LoRA روی Fill	فقط VITON-HD	۶/۰۶۸	مقیاس ۳۰۰۳۰ گام
FLUX رسمی CatVTON	LoRA نویسنده ۳۷۰ مگ	اعلام نشده در مقاله	منتشر نشده	۳۰ Guidance در Atelier
FLUX Beta	fine-tune کامل حدود ۲۳/۸ گیگ	تنوع لباس بیشتر	منتشر نشده	۳۰ Guidance در Atelier

زمان روی لپ‌تاپم

Fast 384×512 ۱۱ ثانیه

Balanced 576×768 ۱۹ ثانیه

با Mix روی RTX 4070 Laptop هشت گیگ، سپتامبر ۲۰۲۶. VRAM حدود ۵/۹ از ۸/۰ گیگ. Quality و Studio و FLUX بومی را روی این کارت زمان نگرفته‌ام.

هر مدل را چرا گذاشتم

Mix — پیش‌فرض روزمره

VAE شخص ماسک‌شده و لباس را جدا به latent می‌برد. این دو از جهت ارتفاع به هم می‌چسبند. UNet اینپیننت SD 1.5 با DDIM نویز را کم می‌کند. چیزی که Mix را Mix می‌کند فقط وزن self-attention است: حدود ۴۹/۵۷ میلیون پارامتر، آموزش‌دیده روی ۴۸ هزار جفت ترکیبی در ۱۰۲۴ پیکسل. این را پیش‌فرض گذاشتم چون بالاپوش، شلوار و ست را پوشش می‌دهد و روی لپ‌تاپم در Balanced پایدار مانده. چاپ و بافت از FLUX عقب‌تر است.

VITON-HD — پیراهن و کت

همان موتور Mix؛ فقط فایل attention عوض می‌شود. روی حدود ۱۶ هزار جفت بالاتنه در ۵۱۲ پیکسل آموزش دیده. برای کاتالوگ بالاتنه نگهش داشتیم. تنوع دسته کم است.

شناسه vitonhd-16k-512 · catvton-vitonhd

DressCode — پیراهن و تنوع

آداپتور dresscode-16k-512 روی DressCode آموزش دیده. وقتی پیراهن شب یا ست کامل می‌خواهم سراغ همین می‌روم. FID زوجی ۳/۹۹۲ مقاله برای همین خانواده روی DressCode است، نه برای Mix.

شناسه dresscode-16k-512 · catvton-dresscode

Mask-Free — عکس‌های شلوغ

در مقاله روی InstructPix2Pix آموزش دیده. در Atelier همان UNet اینپینت را بار می‌کنم و فقط آداپتور توجه را از CatVTON-MaskFree می‌گیرم. وقتی ماسک پاره است سراغش می‌روم. روی عکس تمیز انتظار ارتقای کیفیت ندارم.

شناسه zhengchong/CatVTON-MaskFree · catvton-maskfree

FLUX رسمی — بیشترین وفاداری نویسنده

FluxFill یک ترنسفورمر بزرگ است. شخص و لباس را کنار هم می‌چسبانم. LoRA رسمی حدود ۳۷ مگ است. Guidance را ۳۰ گذاشتم. نور و چین از SD بهتر است؛ روی هشت گیگ فقط با Offload یا ۴-بیت و خیلی کند جلو می‌رود.

شناسه concat person_first · Guidance 30 · catvton-flux

FLUX Alpha — لوگو و بافت

LoRA جامعه روی VITON-HD، ترتیب garment_first. وقتی لوگو و نوشته مهم است این را برمی‌دارم. FID اعلامی ۶/۰۶۸ LoRA است؛ پروتکل با مقاله یکی نیست.

شناسه xiaozaa/catvton-flux-lora-alpha · catvton-flux-alpha

FLUX Beta — تنوع لباس

کل ترنسفورمر را با وزن fine-tune جامعه — حدود ۲۳/۸ گیگ — عوض می‌کنم. تنوع لباسش از Alpha بیشتر است. سنگین‌ترین داندلود را دارد.

شناسه xiaozaa/catvton-flux-beta · catvton-flux-beta

جمع‌بندی عملی در Atelier

مدل	بهترین کاربرد	VRAM	ورود	ماسک	نقطه قوت	نقطه ضعف
Mix	روزمره	۸ گیگ	لازم نیست	تمیز	تعادل پوشش	جزئیات کمتر از FLUX
VITON-HD	بالاتنه	۸ گیگ	لازم نیست	تمیز	پیراهن و کت	لباس کامل ضعیف
DressCode	پیراهن و ست	۸ گیگ	لازم نیست	تمیز	تنوع دسته	آموزش ۵۱۲ پیکسل
Mask-Free	عکس شلوغ	۸ گیگ	لازم نیست	تحمل خطا	ماسک خراب	ارتقای کیفیت نیست
FLUX	کیفیت بالا	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	نور و پارچه	بدون FID رسمی
FLUX Alpha	لوگو و بافت	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	چاپ کوچک	فقط بالاتنه
FLUX Beta	تنوع لباس	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	پوشش وسیع	سنگین‌ترین وزن

چالش‌ها

ویندوز و دانلود وزن

لایه XET در Hugging Face روی ویندوز مدام گیر کرد. XET را خاموش کردم و یک اسکریپت curl با ادامهٔ دانلود گذاشتم. UNet رسمی SD 1.5 هم gated است؛ اول یک آینهٔ عمومی را امتحان می‌کنم.

هشت گیگ در برابر FLUX

کارت من ۸ گیگ است. SD 1.5 در Balanced جا می‌شود. FLUX بومی ۲۴ گیگ می‌خواهد. Offload و -۴ بیت اجرا را ممکن می‌کنند، ولی خیلی کند. برای همین فاصله Hugging Face را هم گذاشتم.

ماسک ساده‌تر از مقاله

مقاله DensePose و SCHP دارد. من SegFormer را روی CPU گذاشتم تا GPU برای دیفیوژن آزاد بماند. نصب راحت‌تر شد؛ لبهٔ ماسک ممکن است ضعیف‌تر باشد.

لایسنس غیرتجاری

وزن‌های CatVTON و SD تحت CC BY-NC-SA 4.0 هستند. FLUX.1 [dev] هم غیرتجاری و gated است. اگر روزی کار تجاری بخواهم، باید مدل یا مجوز جدا بگیرم.

هر خانواده کجا اذیت می‌کند

خانواده	چالش اصلی	اثرش برای کار من
هر چهار SD	وابستگی به ماسک تمیز (جز Mask-Free)	ژست سخت یا پس‌زمینه شلوغ لباس را پاره می‌کند
Mix	جدول رسمی جدا ندارد	کیفیت را با چشم می‌سنجم نه با FID اختصاصی
VITON-HD / DressCode	تخصص داده	اگر دسته را عوضی انتخاب کنم کیفیت می‌افتد
Mask-Free	FID زوجی کمی بدتر	فقط وقتی ماسک خراب است می‌ارزد
هر سه FLUX	دانلود gated و حجم بالا	بدون login بار اول ممکن است بشکند
FLUX Alpha	آموزش فقط بالاتنه	پایین‌تنه و پیراهن ضعیف‌تر از Beta
FLUX Beta	وزن کامل ترنسفورمر	تعویض مدل کل VRAM را خالی و دوباره پر می‌کند

کی کدام را برمی‌دارم

سناریو	انتخاب اول	انتخاب دوم	چرا
لپ‌تاپ ۸ گیگ، تست روزانه	Mix + Balanced	Mix + Fast	پایدار، سریع، بدون login
کاتالوگ پیراهن و کت	VITON-HD	FLUX Alpha روی HF	داده بالاتنه
پیراهن شب یا ست کامل	DressCode	FLUX Beta روی HF	تنوع دسته
سلفی یا ماسک پاره	Mask-Free	Mix با نوع لباس درست	تحمل خطای ماسک
لوگو و نوشته روی پارچه	FLUX Alpha	FLUX رسمی	جزئیات گرافیکی
بهترین کیفیت ممکن	FLUX روی ۲۴ گیگ یا HF	Mix با Quality	سقف ادراکی بالاتر
تولید تجاری	هیچ‌کدام از این وزن‌ها	مدل دارای مجوز	همه غیرتجاری‌اند

حرف آخر

روی کاغذ، CatVTON اینپینت از IDM-VTON و OOTDiffusion هم دقیق‌تر است و هم سبک‌تر: FID زوجی VITON-HD برابر ۵/۴۲۵، DressCode برابر ۳/۹۹۲، حدود ۴ گیگ حافظه و ۹/۲۵ ثانیه در ۷۶۸×۱۰۲۴ روی سخت‌افزار مقاله. Mask-Free کمی از اینپینت ضعیف‌تر است، ولی به ماسک سخت وابسته نیست.

همان خانواده را با چهار آداپتور روی یک UNet سوار کردم. روی RTX 4070 هشت گیگ، Fast حدود ۱۱ ثانیه و Balanced حدود ۱۹ ثانیه طول می‌کشد. FLUX سقف کیفیت را بالا می‌برد، ولی ورود و لایسنس و دانلود و VRAM را هم بالا می‌برد. برای کار روزمره روی این ماشین Mix کافی است. FLUX را وقتی برمی‌دارم که جزئیات پارچه واقعاً می‌ارزد و کارت بزرگ یا Hugging Face دم دست است.

منابع

نوشته میلاد حسنی. عدهای جدول بنچمارک را از جداول ۱ تا ۳ مقاله CatVTON برداشتم مگر جایی که خلافتش را نوشتم. زمان لپ‌تاپ را خودم با Mix روی RTX 4070، هشت گیگ، در سپتامبر ۲۰۲۶ گرفتم. اعداد مقاله روی A800 است و با زمان من

1. Zheng Chong, Xiao Dong, Haoxiang Li, Shiyue Zhang, Wenqing Zhang, Xujie Zhang, Hanqing Zhao, and Xiaodan Liang. CatVTON: Concatenation Is All You Need for Virtual Try-On with Diffusion Models. ICLR 2025. arXiv:2407.15886. <https://arxiv.org/abs/2407.15886>
2. Zheng Chong et al. وزن‌های عمومی CatVTON و LoRA رسمی CatVTON و FLUX. CatVTON-MaskFree و FLUX. zhengchong/CatVTON لایسنس CC BY-NC-SA 4.0
3. Seunghwan Choi, Sunghyun Park, Minsoo Lee, and Jaegul Choo. VITON-HD: High-Resolution Virtual Try-On via Misalignment-Aware Normalization. CVPR 2021. arXiv:2103.16874
4. Davide Morelli, Matteo Fincato, Marcella Cornia, Federico Landi, Fabio Cesari, and Rita Cucchiara. Dress Code: High-Resolution Multi-Category Virtual Try-On. ECCV 2022. arXiv:2204.08532
5. Yisol Choi, Sangkyung Kwak, Sohyun Park, Hyungwon Choi, and Jinwoo Shin. Improving Diffusion Models for Authentic Virtual Try-on in the Wild (IDM-VTON). ECCV 2024. arXiv:2403.05139
6. Yuhao Xu, Tao Gu, Weifeng Chen, and Chengcai Chen. OOTDiffusion: Outfitting Fusion based Latent Diffusion for Controllable Virtual Try-on. 2024. arXiv:2403.01779
7. Zhenyu Xie, Zaiyu Huang, Xin Dong, Fuwei Zhao, Haoye Dong, Xijin Zhang, Feida Zhu, and Xiaodan Liang. GP-VTON: Towards General Purpose Virtual Try-On via Collaborative Local-Flow Global-Parsing Learning. CVPR 2023. arXiv:2303.13756
8. Jeongho Kim, Gyojung Gu, Minho Park, Sunghyun Park, and Jaegul Choo. StableVITON: Learning Semantic Correspondence with Latent Diffusion Model for Virtual Try-On. CVPR 2024. arXiv:2312.01725
9. Davide Morelli, Alberto Baldrati, Marcella Cornia, Marco Bertini, and Rita Cucchiara. LaDI-VTON: Latent Diffusion Textual-Inversion Enhanced Virtual Try-On. ACM MM 2023. arXiv:2305.13501
10. Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, and Eero P. Simoncelli. Image Quality Assessment: From Error Visibility to Structural Similarity (SSIM). IEEE TIP, 2004
11. Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric (LPIPS). CVPR 2018. arXiv:1801.03924
12. Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium (FID). NeurIPS 2017. arXiv:1706.08500
13. Mikołaj Bińkowski, Danica J. Sutherland, Michael Arbel, and Arthur Gretton. Demystifying MMD GANs (KID). ICLR 2018. arXiv:1801.01401
14. Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR 2022. arXiv:2112.10752
15. Tim Brooks, Aleksander Holynski, and Alexei A. Efros. InstructPix2Pix. CVPR 2023. arXiv:2211.09800
16. Enze Xie et al. SegFormer. NeurIPS 2021. [mattmdjaga/segformer_b2_clothes](https://github.com/mattmdjaga/segformer_b2_clothes): پارس لباس
17. Black Forest Labs. FLUX.1-Fill-dev. 2024. huggingface.co/black-forest-labs/FLUX.1-Fill-dev
18. CATVTON-Flux (Alpha و Beta). github.com/nftblackmagic/catvton-flux xiaozaa / nftblackmagic. 2024.

