

مدل‌های Virtual Try-On

میلاد حسنی

Virtual Try-On را روی لپ‌تاپ خودم ساختم، RTX 4070 با هشت گیگ. خواستم بگویم هر گزینه را برای چه گذاشته‌ام، روی چه لباسی بهتر جواب می‌دهد، و از این کارت چه برمی‌آید. آموزش دوباره در کار نبود؛ فقط اجرا. هفت وزن همین‌جا بار می‌شوند. Gemini و Space هاگینگ‌فیس را برای وقتی گذاشتم که GPU پر است یا برای FLUX کم می‌آید — همان عکس شخص و لباس می‌روند بیرون و وزن سنگین روی لپ‌تاپ نمی‌نشیند.

۵,۴۲۵

بهترین FID مقاله روی

VITON-HD

ابر

Gemini با کلید CatVTON

روی Space HF

۸ گیگ

SD روی همین کارت جا

می‌شود

۹

گزینه در منو ۷۰ وزن محلی +

۲ ابری

چطور چیدمش

چک‌پوینت یعنی چه

همان فایل وزن است؛ اعدادی که شبکه یاد گرفته. مقاله می‌گوید weights، هاگینگ‌فیس می‌گوید checkpoint. نه تا گزینه در منو هست، ولی نه تا شبکه جدا نیست. Mix و VITON-HD و DressCode یک UNet را شریک‌اند و فقط فایل توجه را عوض می‌کنند — حدود ۱۹۸ مگ. Mask-Free جداست: UNet هشت‌کاناله Pix2Pix. سه تا FLUX وزن Fill یا LoRA می‌آورند. Gemini و Space اصلاً وزن محلی نمی‌گیرند.

ورودی همیشه ساده‌ست: یک عکس از آدم، یک عکس از لباس، و اینکه بالاتنه می‌خواهم یا پایین‌تنه یا کل استایل. عکس شخص را از وسط می‌برم روی بوم ۴:۳؛ لباس را با حاشیه سفید به همان اندازه می‌رسانم. مقاله برای ماسک DensePose و SCHP دارد؛ من SegFormer را گذاشتم تا روی ویندوز بدون Detectron2 بالا بیاید. بعد یکی از این چهار تا صدا زده می‌شود: اینپینت FLUX، Pix2Pix، SD، یا ابر. اگر چیزی خراب شود دیگر فقط توک ترمینال نمی‌ماند؛ نوار بالا قرمز می‌شود و همان متن را نشان می‌دهد. وسط کار Generate قفل است و Stop فقط وقتی کاری در جریان است روشن می‌شود.

FLUX و ابر FLUX.1-Fill-dev gated است و Guidance اش ۳۰٪ روی کارت کوچک Offload یا ۴-بیت می‌رود، ولی کند. Gemini با کلید AI Studio و Space عمومی CatVTON روی ZeroGPU هیچ وزنی روی لپ‌تاپ بار نمی‌کنند. FLUX · Alpha · Beta · Gemini · HF Space	Mask-Free — Pix2Pix UNet هشت‌کاناله، نه اینپینت، شخص و لباس کنار هم می‌نشینند. Guidance همان ۲/۵. ماسک به شبکه نمی‌رود؛ اگر Top باشد بعداً شلوار و صورت را از عکس اصلی برمی‌گردانم. ۸ · catvton-maskfree کانال	SD 1.5 اینپینت — سه تا وزن توجه یک UNet مشترک، حدود هشت گیگ. مدل که عوض می‌شود فقط همان ۱۹۸ مگ توجه جابه‌جا می‌شود. Guidance را ۲/۵ گذاشتم. ورود Hugging Face نمی‌خواهد. Mix · VITON-HD · DressCode
---	--	---

کیفیت را از منو عوض می‌کنم. Tiny می‌شود ۲۸۴×۲۵۶ و ۱۶ گام، Fast ۲۸۴×۵۱۲ و ۲۰ گام، Balanced — همان که روزمره باهاش کار می‌کنم — ۷۶۸×۵۷۶ و ۳۰ گام، Quality ۷۶۸×۱۰۲۴ و ۵۰ گام است، Studio ۱۰۲۴×۱۲۸۰ و ۳۶ گام. اگر VRAM روی Auto باشد و کارت از ۲۴ گیگ کوچک‌تر، FLUX خودش Offload یا ۴-بیت می‌شود.

این چهار عدد یعنی چه

مقاله چهار تا عدد می‌دهد. دوتای اول یک جفت عکس را با هم می‌سنجند: خروجی من کنار عکس واقعی همان آدم با همان لباس. دوتای بعدی کل خروجی‌ها را با کل عکس‌های واقعی مقایسه می‌کنند، حتی وقتی جفت دقیق نداری.

معیار	چه می‌گوید	بهتر بودن	بازه	کجا گول می‌زند
SSIM	پنجره‌به‌پنجره چقدر شبیه عکس واقعی است	بیشتر، نزدیک ۱	۰ تا ۱	عکس تار ولی تراز را گاهی بهتر از عکس تیز کمی جابه‌جا می‌داند
LPIPS	چشم شبکه چقدر فرق حس می‌کند	کمتر	معمولاً ۰/۴ تا ۰/۲۰	به همان شبکه وابسته است؛ صورت را جدا امتیاز نمی‌دهد
FID	کل خروجی‌ها چقدر شبیه عکس‌های واقعی‌اند	کمتر	بدون واحد؛ اینجا حدود ۳ تا ۱۵	با عوض شدن کد یا تعداد عکس، عدد جابه‌جا می‌شود
KID	همان ایده، روی مجموعه کوچک آرام‌تر	کمتر	بدون واحد	باز هم از همان فضای Inception می‌آید

SSIM

پنجره‌به‌پنجره با عکس واقعی مقایسه می‌کند: روشنایی، کنتراست، لبه. عدد بین صفر و یک است. برای من SSIM بالا یعنی صورت و مو و پس‌زمینه سر جایش مانده، نه لزوماً اینکه لباس قشنگ‌تر شده. در جدول مقاله اینپینت CatVTON روی VITON-HD به ۰/۸۷۰۴ می‌رسد — نزدیک است، یکی نیست.

LPIPS

دیگر پیکسل خام نیست. تکه‌های عکس از یک شبکه مثل VGG رد می‌شوند و فاصله‌شان حساب می‌شود. چشم به بافت و چین بیشتر از اختلاف RGB گیر می‌دهد؛ این همان را تقریب می‌زند. کمتر بهتر است. اگر لباس درست بنشیند ولی رنگ کمی فرق کند، LPIPS بیشتر از SSIM شکایت می‌کند. عدد اینپینت روی ۰/۰۵۶۵ VITON-HD است.

FID

این یکی برای یک جفت عکس نیست. همه عکس‌های واقعی و همه خروجی‌ها می‌روند توی Inception، از هر دسته میانگین گرفته می‌شود، و می‌بینند دو توده چقدر از هم دورند. FID پایین یعنی خروجی‌ها شبیه عکس واقعی‌اند. مشکلش این است که با عوض شدن کد یا تعداد عکس، عدد جابه‌جا می‌شود. برای همین FIDهایی که برای FLUX در جامعه دیده‌ام را با جدول مقاله قاطی نمی‌کنم.

KID

همان فضا، بدون آن فرض آماری FID. روی چند هزار عکس معمولاً آرام‌تر است. مقاله هر دو را می‌دهد چون FID را همه می‌شناسند و KID روی این مجموعه‌ها کمتر می‌پرد. روی VITON-HD زوجی، CatVTON به ۰/۴۱۱ می‌رسد و OOTDiffusion به ۴/۰۸۶.

قبل از مدل چه کار می‌کنم

هر نه تا از همان شخص و لباس و نوع لباس شروع می‌شوند. از اینجا به بعد راهنشان جدا می‌شود.

گام	چه می‌کند	کجا در کد
۱. بوم	عکس آدم را از وسط می‌برم؛ لباس را با حاشیه سفید هم‌اندازه می‌کنم	resize_and_crop / padding
۲. پارس بدن	SegFormer لباس را به ۱۸ تکه می‌زند؛ صورت، لباس بالا، شلوار، دست. روی CPU می‌ماند تا GPU آزاد بماند	ClothMasker
۳. ماسک	برای Mix و بقیه اینپینت‌ها، بسته به Top / Bottom / Full look ناحیه گشاد می‌شود و صورت و مو می‌مانند. Mask-Free این را به UNet نمی‌دهد	build_agnostic_mask
۴. لبه	ماسک اینپینت را کمی محو می‌کنم تا مرز لباس پاره نشود	blur_mask
۵. ساخت	اینپینت Gemini، FLUX، Pix2Pix، SD، یا Space هاگینگ‌فیس	catvton / flux_tryon / cloud
۶. قفل	در Mask-Free اگر Top باشد شلوار و پا و کفش و صورت را از عکس اصلی برمی‌گردانم	composite_tryon

مقاله DensePose و SCHP دارد. من SegFormer را گذاشتم چون نصب ویندوز ساده‌تر شد. Mask-Free را برای وقتی گذاشتم که ماسک روی بند و چاپ شلوغ گیر می‌کند — با UNet درست Pix2Pix، نه اینپینت نه‌کاناله.

اعداد مقاله

فقط این را نگه دار


FID و KID هرچه کمتر بهتر. SSIM هرچه بیشتر بهتر. LPIPS هرچه کمتر بهتر. زوجی یعنی عکس مرجع هست. غیرزوجی فقط می‌گوید خروجی‌ها شبیه عکس‌های واقعی‌اند. عددهای FLUX جامعه را جدا نگه داشتیم؛ با همین روش مقاله گرفته نشده‌اند.

FID زوجی روی VITON-HD — کمتر بهتر است




جدول ۱ مقاله، VITON-HD زوجی، FID واحد ندارد؛ کمتر بهتر است.

زمان مقاله در ۷۶۸×۱۰۲۴



جدول ۲ همان مقاله. روی کارت دیتاسنتر گرفته‌اند، نه لپ‌تاپ من.

حافظه — گیگابایت



جدول ۳ مقاله، به‌علاوهٔ Balanced روی لپ‌تاپ خودم.

جدول مقاله روی VITON-HD

روش	↑ SSIM	↓ FID زوجی	↓ KID زوجی	↓ LPIPS	↓ FID غیرزوجی	↓ KID غیرزوجی
CatVTON اینپینت	۰٫۸۷۰۴	۵٫۴۳۵	۰٫۴۱۱	۰٫۰۵۶۵	۹٫۰۱۵	۱٫۰۹۱
CatVTON Mask-Free	۰٫۸۷۰۱	۵٫۸۸۸	۰٫۵۱۳	۰٫۰۶۱۳	۹٫۲۸۷	۱٫۱۶۸
IDM-VTON	۰٫۸۴۹۹	۵٫۷۶۳	۰٫۷۳۳	۰٫۰۶۰۳	۹٫۸۴۳	۱٫۱۲۳
OOTDiffusion	۰٫۸۱۸۷	۹٫۳۰۵	۴٫۰۸۶	۰٫۰۸۷۶	۱۲٫۴۰۸	۴٫۶۸۹
GP-VTON	۰٫۸۷۰۱	۸٫۷۳۶	۳٫۹۴۴	۰٫۰۵۸۵	۱۱٫۸۴۴	۴٫۳۱۰
StableVTON	۰٫۸۵۴۳	۶٫۴۳۹	۰٫۹۴۳	۰٫۰۹۰۵	۱۱٫۰۵۴	۳٫۹۱۴
LaDI-VTON	۰٫۸۶۰۳	۱۱٫۳۸۶	۷٫۳۴۸	۰٫۰۷۳۳	۱۴٫۶۴۸	۸٫۷۵۴

جدول مقاله روی DressCode

روش	↑ SSIM	↓ FID زوجی	↓ KID زوجی	↓ LPIPS	↓ FID غیرزوجی	↓ KID غیرزوجی
CatVTON اینپینت	۰٫۸۹۳۳	۳٫۹۹۳	۰٫۸۱۸	۰٫۰۴۵۵	۶٫۱۳۷	۱٫۴۰۳
CatVTON Mask-Free	۰٫۹۰۱۶	۴٫۷۷۹	۱٫۲۹۷	۰٫۰۴۵۲	۷٫۴۰۰	۲٫۶۱۹
OOTDiffusion	۰٫۸۸۵۴	۴٫۶۱۰	۰٫۹۵۵	۰٫۰۵۳۳	۱۲٫۵۶۷	۶٫۶۳۷
IDM-VTON	۰٫۸۷۹۷	۶٫۸۳۱	۲٫۹۳۴	۰٫۰۵۶۳	۹٫۵۴۶	۴٫۳۲۰
GP-VTON	۰٫۷۷۱۱	۹٫۹۳۷	۴٫۶۱۰	۰٫۱۸۰۱	۱۲٫۷۹۱	۶٫۶۳۷
LaDI-VTON	۰٫۷۶۵۶	۹٫۵۵۵	۴٫۶۸۳	۰٫۳۳۶۶	۱۰٫۶۷۶	۵٫۷۸۷

وزن DressCode مقاله فقط روی DressCode یاد گرفته. Mix که من پیش‌فرض گذاشتم روی حدود ۴۸ هزار جفت قاطی در ۱۰۲۴ پیکسل یاد گرفته و جدول جدا در مقاله ندارد.

چرا سبک است

روش	کل پارامتر (میلیون)	آنچه یاد گرفته (میلیون)	حافظه (گیگ)	زمان ۲۸۴×۵۱۲	زمان ۷۶۸×۱۰۲۴
CatVTON	۸۹۹	۴۹٫۵۷	۴٫۰۰	۲٫۵۸ ثانیه	۹٫۲۵ ثانیه
StableVTON	۱۶۰۸	۵۰۱	۷٫۸۷	۱۲٫۱۷ ثانیه	۳۶٫۱۰ ثانیه
OOTDiffusion	۲۱۹۱	۱۷۱۹	۱۰٫۲۰	۴٫۷۶ ثانیه	۳۶٫۲۳ ثانیه
IDM-VTON	۶۲۳۸	۲۸۷۱	۲۶٫۰۴	۱۲٫۹۶ ثانیه	۱۷٫۳۳ ثانیه

جداول ۲ و ۳. CatVTON انکودر متن و ReferenceNet را برداشته و فقط self-attention را یاد داده.

عدهای FLUX جامعه — داستان جدا

این‌ها را با جدول بالا جمع نمی‌زنم

نویسنده‌شان FID را با مقیاس ۳۰ و ۳۰ گام روی VITON-HD گفته. ماسک و اندازه عکس و کد تست با مقاله یکی اعلام نشده.

وزن	نوع	روی چه یاد گرفته	FID گفته شده	تست
FLUX Alpha کامل	fine-tune ترنسفورمر	فقط VITON-HD	۵٫۵۹۳	مقیاس ۳۰۰۳۰ گام
FLUX LoRA Alpha	LoRA روی Fill	فقط VITON-HD	۶٫۰۶۸	مقیاس ۳۰۰۳۰ گام
FLUX نویسنده‌ها	LoRA نویسنده ۳۷۰ مگ	در مقاله نیامده	منتشر نشده	۳۰ Guidance در Virtual Try-On
FLUX Beta	fine-tune کامل حدود ۲۳٫۸ گیگ	تنوع لباس بیشتر	منتشر نشده	۳۰ Guidance در Virtual Try-On

زمان روی لپ‌تاپم

Fast 384×512 ۱۱ ثانیه

Balanced 576×768 ۱۹ ثانیه

با Mix روی RTX 4070 Laptop هشت گیگ، سپتامبر ۲۰۲۶، VRAM حدود ۵٫۹ از ۸٫۰ گیگ، Quality و Studio و FLUX بومی را روی این کارت زمان نگرفته‌ام.

چرا این‌ها را گذاشتم

Mix — همان که هر روز می‌زنم

روزمره سراغ Mix می‌روم. همان اینپینت SD است؛ فرقی این است که توجه‌اش روی حدود ۴۸ هزار جفت قاطی در ۱۰۲۴ پیکسل یاد گرفته، هم بالاپوش هم شلوار. روی لپ‌تاپم در Balanced پایدار مانده و login نمی‌خواهد. چاپ و بافت هنوز از FLUX عقب است.

شناسه catvton-mix · zhengchong/CatVTON · mix-48k-1024 · Guidance 2.5

VITON-HD — پیراهن و کت

موتورش همان Mix است؛ فقط فایل توجه عوض می‌شود. روی پیراهن و کت یاد گرفته. برای کاتالوگ بالاتنه نگهش داشتم. اگر شلوار یا ست کامل بخواهم سراغش نمی‌روم.

شناسه catvton-vitonhd · vitonhd-16k-512

DressCode — پیراهن و تنوع

وقتی پیراهن شب یا ست کامل می‌خواهم این را برمی‌دارم. آن FID زوجی ۳٫۹۹۲ مقاله مال همین خانواده روی DressCode است، نه مال Mix.

شناسه catvton-dresscode · dresscode-16k-512

Mask-Free — عکس‌های شلوغ

این یکی ماسک را به شبکه نمی‌دهد. شخص و لباس کنار هم می‌نشینند و مدل خودش حدس می‌زند کجا لباس عوض شود. اول اشتباهاً UNet اینپینت را بار کردم و لباس را کند، نه اینکه بیوشاند. حالا Pix2Pix درست است. مشکل بعدی این بود که با Top گاهی شلووار را هم عوض می‌کرد؛ برای همین بعد از ساخت شلووار و پا و کفش و صورت را از عکس اصلی برمی‌گردانم. روی عکس تمیز از Mix بهتر نیست.

شناسه catvton-maskfree · zhengchong/CatVTON-MaskFree · timbrooks/instruct-pix2pix

Gemini — ابر Google

وزن محلی بار نمی‌شود. شخص و لباس می‌روند بیرون و یک عکس try-on برمی‌گردد. کلید را از aistudio.google.com/apikey در فیلد UI می‌گذارم؛ روی همین ماشین در secrets.json می‌ماند و به git نمی‌رود. اول gemini-3.1-flash-image را می‌زنم، اگر مدل نبود gemini-2.5-flash-image. وقتی GPU مشغول است یا برای FLUX کوچک، این را برمی‌دارم. بدون کلید، بنر خطا همان لینک AI Studio را نشان می‌دهد.

شناسه gemini-flash · کلید Google AI Studio · بدون VRAM محلی

Space — Hugging Face عمومی CatVTON

همان ایده ابری، ولی موتور CatVTON است نه Gemini. Space نویسنده‌ها zhengchong/CatVTON اغلب RUNTIME_ERROR است. زنده بودن را چک می‌کنم و سراغ trytonvirtual/virtual-tryon یا Nandha2017/virtual-tryon می‌روم — هر دو روی ZeroGPU A10G. بدون توکن سهمیه کم است؛ یک بار ۱۸۰ ثانیه خواست و ۱۷۶ ثانیه مانده بود. توکن hf_ از huggingface.co/settings/tokens همان توکن دانلود gated فلکس را هم باز می‌کند.

شناسه ZeroGPU · hf-catvton · توکن اختیاری

FLUX نویسنده‌ها — نور و چین

LoRA خود نویسنده‌های CatVTON روی FluxFill، حدود ۳۷ مگ. Guidance را ۳۰ گذاشتم. نور و چین از SD بهتر است؛ روی هشت گیگ فقط با Offload یا ۴-بیت جلو می‌رود و کند است.

شناسه catvton-flux · Guidance 30 · concat person_first

FLUX Alpha — لوگو و بافت

LoRA جامعه روی VITON-HD. وقتی لوگو و نوشته روی پارچه مهم است این را برمی‌دارم. یک FID ۶/۰۶۸ گفته‌اند؛ با جدول مقاله قاطی‌اش نمی‌کنم.

شناسه catvton-flux-alpha · xiaozaa/catvton-flux-lora-alpha

FLUX Beta — تنوع لباس

کل ترنسفورمر را عوض می‌کند، حدود ۲۳/۸ گیگ. تنوع لباسش از Alpha بیشتر است و سنگین‌ترین دانلود را دارد.

شناسه catvton-flux-beta · xiaozaa/catvton-flux-beta

یک نگاه سریع

مدل	بهترین کاربرد	VRAM	ورود	ماسک	نقطه قوت	نقطه ضعف
Mix	روزمره	۸ گیگ	لازم نیست	تمیز	تعادل پوشش	جزئیات کمتر از FLUX
VITON-HD	بالاتنه	۸ گیگ	لازم نیست	تمیز	پیراهن و کت	لباس کامل ضعیف
DressCode	پیراهن و ست	۸ گیگ	لازم نیست	تمیز	تنوع دسته	آموزش ۵۱۲ پیکسل
Mask-Free	عکس شلوغ	۸ گیگ	لازم نیست	Pix2Pix + قفل شلوار در Top	ماسک خراب	بدون قفل، پایین‌تنه را هم عوض می‌کند
Gemini	GPU مشغول یا کوچک	ابر	کلید AI Studio	بدون ماسک محلی	VRAM صفر	هزینه API • عکس به Google می‌رود
HF Space	CatVTON در ابر	ابر	توکن اختیاری	ماسک Space	بدون بار محلی	سه‌میه Space • ZeroGPU نویسنده‌ها غالباً خراب است
FLUX	کیفیت بالا	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	نور و پارچه	FID مقاله ندارد
FLUX Alpha	لوگو و بافت	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	چاپ کوچک	فقط بالاتنه
FLUX Beta	تنوع لباس	۲۴ گیگ+	HF + لایسنس	ماسک + Fill	پوشش وسیع	سنگین‌ترین وزن

چالش‌ها

ویندوز و دانلود وزن

لایه XET در Hugging Face روی ویندوز مدام گیر کرد. XET را خاموش کردم و یک اسکریپت curl با ادامهٔ دانلود گذاشتم. UNet خود SD 1.5 هم gated است؛ اول یک آینهٔ عمومی را امتحان می‌کنم.

هشت گیگ در برابر FLUX

کارت من ۸ گیگ است. SD 1.5 در Balanced جا می‌شود. FLUX بومی ۲۴ گیگ می‌خواهد. Offload و -۴ بیت اجرا را ممکن می‌کنند، ولی خیلی کند. برای همین Gemini و Space هاگینگ‌فیس را هم گذاشتم تا وزن سنگین روی این لپ‌تاپ ننشیند.

Mask-Free بدون قفل شلوار

Pix2Pix ماسک اینپینت ندارد. با Top، یک بار شلوار سوژه را هم عوض کرد. بعد از ساخت، شلوار و پا و کفش و صورت را از عکس اصلی برمی‌گردانم. اگر پارس شلوار را نبیند، قفل کامل نیست.

سهمیۀ ZeroGPU و کلید Gemini

Space زنده است و صف و آپلود کار می‌کند، ولی بدون توکن hf_ سهمیۀ مهمان کم است. Gemini بدون کلید اصلاً نمی‌رود؛ متن خطا باید بالا دیده شود، نه فقط در ترمینال. کلید و توکن را در secrets.json می‌گذارم.

ماسک ساده‌تر از مقاله

مقاله DensePose و SCHP دارد. من SegFormer را روی CPU گذاشتم تا GPU برای ساخت آزاد بماند. نصب راحت‌تر شد؛ لبۀ ماسک ممکن است ضعیف‌تر باشد.

لایسنس غیرتجاری

وزن‌های CatVTON و SD تحت CC BY-NC-SA 4.0 هستند. FLUX.1 [dev] هم غیرتجاری و gated است. Gemini شرایط Gemini API گوگل را دارد و عکس را از ماشین بیرون می‌برد. اگر روزی کار تجاری بخواهم، باید مدل یا مجوز جدا بگیرم.

کجا گیر می‌کنند

خانواده	گیر اصلی	برای من یعنی
هر سه اینپینت SD	ماسک باید تمیز باشد	ژست سخت یا پس‌زمینه شلوغ لباس را پاره می‌کند
Mix	جدول جدا در مقاله ندارد	کیفیت را با چشم می‌سنجم نه با FID اختصاصی
VITON-HD / DressCode	هر کدام یک دسته لباس	اگر دسته را عوضی انتخاب کنم کیفیت می‌افتد
Mask-Free	FID زوجی کمی بدتر * نشت پایین‌تنه	فقط وقتی ماسک خراب است می‌ارزد؛ Top را قفل می‌کنم
Gemini	کلید و ارسال عکس به Google	بدون کلید نمی‌سازد؛ هزینه با حساب AI Studio است
HF Space	Space نویسندۀ خراب * سهمیۀ ZeroGPU	بدون توکن ممکن است صف پر شود یا ۱۸۰ ثانیه کم بیاید
هر سه FLUX	دانلود gated و حجم بالا	بدون login بار اول ممکن است بشکند
FLUX Alpha	آموزش فقط بالاتنه	پایین‌تنه و پیراهن ضعیف‌تر از Beta
FLUX Beta	وزن کامل ترنسفورمر	تعویض مدل کل VRAM را خالی و دوباره پر می‌کند

کی سراغ کدام می‌روم

سناریو	انتخاب اول	انتخاب دوم	چرا
لپ‌تاپ ۸ گیگ، تست روزانه	Mix + Balanced	Mix + Fast	پایدار، سریع، بدون login
کاتالوگ پیراهن و کت	VITON-HD	FLUX Alpha روی HF	داده بالاتنه
پیراهن شب یا ست کامل	DressCode	FLUX Beta روی HF	تنوع دسته
سلفی یا ماسک پاره	Mask-Free	Mix با نوع لباس درست	Pix2Pix + قفل شلوار در Top
GPU پر یا FLUX روی ۸ گیگ خیلی کند	Gemini	HF Space	VRAM محلی صفر؛ کلید یا توکن
CatVTON در ابر، بدون Gemini	HF Space + توکن	Mix محلی	Space نویسنده‌ها غالباً RUNTIME_ERROR است
لوگو و نوشته روی پارچه	FLUX Alpha	FLUX نویسنده‌ها	جزئیات گرافیکی
بهترین کیفیت ممکن	FLUX روی ۲۴ گیگ	Gemini یا Quality با Mix	سقف ادراکی بالاتر + ابر وقتی VRAM کم است
تولید تجاری	هیچ‌کدام از وزن‌های CatVTON/FLUX	مدل دارای مجوز	CC BY-NC-SA و FLUX.1 [dev] غیرتجاری‌اند؛ جدا Gemini

حرف آخر

اگر فقط عدد مقاله را نگاه کنم، اینپینت CatVTON هم سبک است هم دقیق: FID زوجی ۵/۴۲۵ روی VITON-HD و ۳/۹۹۲ روی DressCode، حدود ۴ گیگ و ۹ ثانیه در ۱۰۲۴ روی کارت خودشان. Mask-Free کمی عقب‌تر است، ولی به ماسک تمیز وابسته نیست.

همان خانواده را روی لپ‌تاپ سوار کردم. با Mix، Fast، حدود ۱۱ ثانیه و Balanced حدود ۱۹ ثانیه. FLUX سقف را بالا می‌برد، ولی ورود و حجم و VRAM را هم با خودش می‌آورد. Gemini و Space را برای وقتی گذاشتم که GPU پر است یا FLUX روی این کارت نمی‌صرفد. روزمره Mix کافی است. Mask-Free را وقتی ماسک پاره است برمی‌دارم. FLUX یا Gemini را وقتی جزئیات پارچه یا کمبود VRAM واقعاً می‌ارزد.

منابع

عددهای جدول را از جداول ۱ تا ۳ مقاله CatVTON برداشتم مگر جایی که خلافتش را نوشتم. زمان لپ‌تاپ را خودم با Mix روی RTX 4070، هشت گیگ، در سپتامبر ۲۰۲۶ گرفتم. اعداد مقاله روی A800 است و با زمان من جمع نمی‌شود.

1. Zheng Chong, Xiao Dong, Haoxiang Li, Shiyue Zhang, Wenqing Zhang, Xujie Zhang, Hanqing Zhao, and Xiaodan Liang. CatVTON: Concatenation Is All You Need for Virtual Try-On with Diffusion Models. ICLR 2025. arXiv:2407.15886. <https://arxiv.org/abs/2407.15886>

2. Zheng Chong et al. وزن‌های عمومی CatVTON و LoRA FLUX نویسنده‌ها. CatVTON- و zhengchong/CatVTON. MaskFree. لایسنس CC BY-NC-SA 4.0.

- Seunghwan Choi, Sunghyun Park, Minsoo Lee, and Jaegul Choo. VITON-HD: High-Resolution Virtual Try-On via .3
Misalignment-Aware Normalization. CVPR 2021. arXiv:2103.16874
- Davide Morelli, Matteo Fincato, Marcella Cornia, Federico Landi, Fabio Cesari, and Rita Cucchiara. Dress Code: .4
High-Resolution Multi-Category Virtual Try-On. ECCV 2022. arXiv:2204.08532
- Yisol Choi, Sangkyung Kwak, Sohyun Park, Hyungwon Choi, and Jinwoo Shin. Improving Diffusion Models for .5
Authentic Virtual Try-on in the Wild (IDM-VTON). ECCV 2024. arXiv:2403.05139
- Yuhao Xu, Tao Gu, Weifeng Chen, and Chengcai Chen. OOTDiffusion: Outfitting Fusion based Latent Diffusion for .6
Controllable Virtual Try-on. 2024. arXiv:2403.01779
- Zhenyu Xie, Zaiyu Huang, Xin Dong, Fuwei Zhao, Haoye Dong, Xijin Zhang, Feida Zhu, and Xiaodan Liang. GP- .7
VTON: Towards General Purpose Virtual Try-On via Collaborative Local-Flow Global-Parsing Learning. CVPR 2023. .
arXiv:2303.13756
- Jeongho Kim, Gyojung Gu, Minho Park, Sunghyun Park, and Jaegul Choo. StableVITON: Learning Semantic .8
Correspondence with Latent Diffusion Model for Virtual Try-On. CVPR 2024. arXiv:2312.01725
- Davide Morelli, Alberto Baldrati, Marcella Cornia, Marco Bertini, and Rita Cucchiara. LaDI-VTON: Latent Diffusion .9
Textual-Inversion Enhanced Virtual Try-On. ACM MM 2023. arXiv:2305.13501
- Zhou Wang, Alan C. Bovik, Hamid R. Sheikh, and Eero P. Simoncelli. Image Quality Assessment: From Error .10
.Visibility to Structural Similarity (SSIM). IEEE TIP, 2004
- Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shechtman, and Oliver Wang. The Unreasonable Effectiveness of .11
Deep Features as a Perceptual Metric (LPIPS). CVPR 2018. arXiv:1801.03924
- Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs Trained by a .12
Two Time-Scale Update Rule Converge to a Local Nash Equilibrium (FID). NeurIPS 2017. arXiv:1706.08500
- Mikołaj Bińkowski, Danica J. Sutherland, Michael Arbel, and Arthur Gretton. Demystifying MMD GANs (KID). ICLR .13
2018. arXiv:1801.01401
- Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-Resolution Image .14
Synthesis with Latent Diffusion Models. CVPR 2022. arXiv:2112.10752
- Tim Brooks, Aleksander Holynski, and Alexei A. Efros. InstructPix2Pix. CVPR 2023. arXiv:2211.09800 .15
- mattmdjaga/segformer_b2_clothes: پارس لباس: Enze Xie et al. SegFormer. NeurIPS 2021 .16
- Black Forest Labs. FLUX.1-Fill-dev. 2024. huggingface.co/black-forest-labs/FLUX.1-Fill-dev .17
- Google. Gemini API .18
gemini-3.1-flash-image. ai.google.dev و gemini-2.5-flash-image مدل تصویر و کلید
.aistudio.google.com/apikey
- zhengchong/CatVTON نویسنده ها Space: ZeroGPU روی CatVTON میزبان های عمومی Hugging Face Spaces .19
Nandha2017/virtual-tryon و tryitovirtual/virtual-tryon: ۲۰۲۶ است. جایگزین های زنده در سپتامبر ۲۰۲۶
2024. github.com/nftblackmagic/catvton-flux. (Beta و Alpha) xiaozaa / nftblackmagic. CATVTON-Flux .20